计算机科学与技术学院自然语言处理课程实验报告

实验题目:实验二 学号: 201600130053

日期: 2019/03/19 班级: 2016 智能班 姓名: 王斌

Email: 935681396@qq.com

实验目的:

要求:使用 StanfordCoreNLP 尝试对中英文两个语料进行句法分析和依存句法分析,使用 LTP 仅对中文语料进行依存句法分析,并对比一下 StanfordCoreNLP 与 LTP 在中文语料上 进行依存句法分析结果的不同。实验结果撰写实验报告。

实验软件和硬件环境:

一、硬件环境:

惠普 PC

二、软件环境:

主机操作系统

Windows 10 家庭中文版 64-bit

平台编程环境

anaconda + python3.7

anaconda + python3.5(pyltp 只找到了 py3.5 的 whl 文件于是装在了 py)

pyltp 3.4.0

stanfordcorenlp 3.9.1.1

实验原理和方法:

对于给定的 chinese_sen.txt (中文 5 句)与 english_sen.txt (英文 3 句)中的句子,分别 进行句法分析和依存句法分析。

注意: StanfordCoreNLP 对于中英文均可,句法分析与依存句法分析都可以胜任,但是哈 工大的 LTP 工具只能进行中文的依存句法分析。句法分析中的常用符号请参考"常用的标注 指代.txt"。

实验步骤: (不要求罗列完整源代码)

一、 使用 Stanford coreNLP 进行中文和英文的句法和依存句法分析:

1、中文原语料:

学历造假风波一月后,翟天临与辛芷蕾牵手回家。

武磊替补登场,梅西独中两元助巴萨2:0战胜西班牙人。

漫威影业官方微博宣布《复仇者联盟4》正式定档4月24日在内地上映。

3月29日下午,呼声极高的人工智能专业被列入新增审批本科专业名单,全国共有35所高校获首批建设资格。

ACM宣布,深度学习的三位创造者Yoshua Bengio,Yann LeCun,以及Geoffrey Hinton获得了2019年的图灵奖。

句法分析结果: (ROOT (IP (IP (LCP (IP (NP (NN) (NN 学历)) (VP (VV 造假) (NP (NP (NN 风波)) (QP (CD -)) (IP (NP (NN 月))))) (NP (LC 后)) (ADJP (JJ 武磊)) (NP (NN 漫威) (NN 影业) (NN 官方) (NN 微博)) (NP (NN 替补))) (PU ,) (VP (W 宣布) (VP (W 登场)))) (VP (VV 翟天) (IP (PU ,) (IP (IP (VP (VP (W 临) ... (NP (NR 梅西独) (NR 中)) (ADVP (AD 正式)) (IP (QP (CD 两) (VP (VV 定) (VP (CLP (M 元))) (IP (VP (VP (NP (NN 档)) (PP (P 与) (VP (VV 助) (VP (NP (NR 辛芷蕾))) (NP (NR 巴萨)) . (NP (NT 4月) (NT 24日)) (VP (VV 牵) (QP (CD 2:0))) (PP (P 在) (NP (NN 手)))) (VP (VV 战胜) (NP (NN 内地))) (VP (W 回家))))))) (NP (NN 西班牙人)))) (VP (W 上映))))))))) (PU 。) (PU 。) (PU 。) (IP (NP (NN ACM)) (VP (W 宣布) (PU ,) (IP (NP (NP (DNP (NP (IP .. (NP (NT 3月) (NT 29日) (NT 下午)) (ADJP (JJ 深度)) (NP (PU ,) (NP (NN 学习))) (DP (DT 全)) (NP (DEG 的)) (CP (NP (NN 国))) (QP (CD ≡) (IP (CLP (M 位))) .. (NP (NN 呼声)) (ADVP (AD 共)) (NP (NN 创造者))) (VP (ADVP (AD 极)) (NP (NR Yoshua) (NR Bengio))) (VP (VE 有) (PÙ ,)

stanfordnlp 依存语法分析:

(NP (NN 本科) (NN 专业) (NN 名单))))))))

(VP (VA 高))))

.. (ADJP (JJ 人工))

. (VP (VV 新增)

(VP (VV 审批)

(NP (NN 智能)))

(NP (NN 专业)))

(IP

(VP (SB 被) (VP (VV 列入)

(PU ,)

(DEC 的))

(IP

(PU 。)

(NP

(QP (CD 35)

(VP (VV 获)

(NP

(CLP (M 所)))

(NP (NN 高校)))

(QP (OD 首)

(CLP (M 批)))

(NP (NN 建设) (NN 资格))))))))

(NP

(NP

(PU 。)))

(PU ,) (CC 以及)

(DNP

(NP (NR Yann) (NR LeCun))

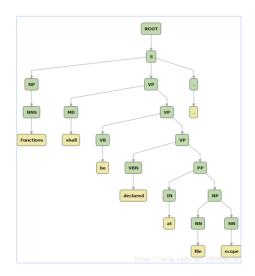
(NP (NT 2019年))

(NP (NN 图灵奖))))))

(DEG 的))

(NP (NR Geoffrey) (NR Hinton))) (VP (W 获得) (AS 了)

stanford 依存句法分析标注树状图:



stanfordcorenlp 依存句法标注详细解释:

ROOT: 要处理文本的语句

IP: 简单从句

NP: 名词短语

VP: 动词短语

PU: 断句符,通常是句号、问号、感叹号等标点符号

LCP: 方位词短语

PP: 介词短语

CP: 由'的'构成的表示修饰性关系的短语

DNP: 由'的'构成的表示所属关系的短语

ADVP: 副词短语

ADJP: 形容词短语

DP: 限定词短语

QP: 量词短语

NN: 常用名词

NR: 固有名词

NT: 时间名词

PN: 代词

vv: 动词

VC: 是

CC:表示连词

VE: 有

VA: 表语形容词

AS: 内容标记(如:了)

VRD: 动补复合词

CD:表示基数词

DT: determiner 表示限定词

EX: existential there 存在句

FW: foreign word 外来词

IN: preposition or conjunction, subordinating 介词或从属连词

JJ: adjective or numeral, ordinal 形容词或序数词

JJR: adjective, comparative 形容词比较级 JJS: adjective, superlative 形容词最高级

LS: list item marker 列表标识MD: modal auxiliary 情态助动词PDT: pre-determiner 前位限定词POS: genitive marker 所有格标记

PRP: pronoun, personal 人称代词

RB: adverb 副词

RBR: adverb, comparative 副词比较级 RBS: adverb, superlative 副词最高级

RP: particle 小品词 SYM: symbol 符号

TO:"to" as preposition or infinitive marker 作为介词或不定式标记

WDT: WH-determiner WH 限定词

WP: WH-pronoun WH 代词

WP\$: WH-pronoun, possessive WH 所有格代词

WRB:Wh-adverb WH 副词

关系表示

abbrev: abbreviation modifier, 缩写

acomp: adjectival complement, 形容词的补充;

advcl: adverbial clause modifier, 状语从句修饰词

advmod: adverbial modifier 状语

agent: agent, 代理, 一般有 by 的时候会出现这个

amod: adjectival modifier 形容词 appos: appositional modifier,同位词

attr: attributive, 属性

aux: auxiliary, 非主要动词和助词,如 BE, HAVE SHOULD/COULD等到

auxpass: passive auxiliary 被动词

cc: coordination,并列关系,一般取第一个词

ccomp: clausal complement 从句补充

complm: complementizer, 引导从句的词好重聚中的主要动词

conj : conjunct, 连接两个并列的词。

cop: copula。系动词(如 be, seem, appear 等), (命题主词与谓词间的)连系

csubj : clausal subject, 从主关系

csubjpass: clausal passive subject 主从被动关系

dep: dependent 依赖关系

det: determiner 决定词,如冠词等 dobj : direct object 直接宾语 expl: expletive, 主要是抓取 there

infmod: infinitival modifier, 动词不定式

iobj : indirect object, 非直接宾语, 也就是所以的间接宾语;

```
mark: marker, 主要出现在有"that" or "whether""because", "when",
mwe: multi-word expression, 多个词的表示
neg: negation modifier 否定词
nn: noun compound modifier 名词组合形式
npadvmod: noun phrase as adverbial modifier 名词作状语
nsubj : nominal subject, 名词主语
nsubjpass: passive nominal subject, 被动的名词主语
num: numeric modifier, 数值修饰
number: element of compound number, 组合数字
parataxis: parataxis: parataxis, 并列关系
partmod: participial modifier 动词形式的修饰
pcomp: prepositional complement, 介词补充
pobj : object of a preposition, 介词的宾语
poss: possession modifier, 所有形式, 所有格, 所属
possessive: possessive modifier, 这个表示所有者和那个'S的关系
preconj : preconjunct, 常常是出现在 "either", "both", "neither"的情况下
predet: predeterminer, 前缀决定, 常常是表示所有
prep: prepositional modifier
prepc: prepositional clausal modifier
prt: phrasal verb particle, 动词短语
punct: punctuation,这个很少见,但是保留下来了,结果当中不会出现这个
purpcl: purpose clause modifier, 目的从句
quantmod: quantifier phrase modifier, 数量短语
rcmod: relative clause modifier 相关关系
ref : referent, 指示物, 指代
rel : relative
root: root, 最重要的词, 从它开始, 根节点
tmod: temporal modifier
xcomp: open clausal complement
xsubj : controlling subject 掌控者
中心语为谓词
subj - 主语
nsubj - 名词性主语(nominal subject) (同步,建设)
top - 主题(topic) (是, 建筑)
npsubj - 被动型主语 (nominal passive subject), 专指由"被"引导的被动句中的主语, 一般
是谓词语义上的受事 (称作,镍)
csubj - 从句主语(clausal subject),中文不存在
xsubj - x 主语,一般是一个主语下面含多个从句 (完善,有些)
中心语为谓词或介词
obj - 宾语
dobj - 直接宾语 (颁布,文件)
iobj - 间接宾语 (indirect object), 基本不存在
range – 间接宾语为数量词,又称为与格 (成交,元)
pobj - 介词宾语 (根据,要求)
```

```
lobj - 时间介词 (来, 近年)
中心语为谓词
comp - 补语
ccomp - 从句补语,一般由两个动词构成,中心语引导后一个动词所在的从句(IP) (出现,纳入)
xcomp - x 从句补语 (xclausal complement), 不存在
acomp - 形容词补语 (adjectival complement)
tcomp - 时间补语(temporal complement) (遇到,以前)
lccomp - 位置补语(localizer complement) (占,以上)
- 结果补语 (resultative complement)
中心语为名词
mod - 修饰语 (modifier)
pass - 被动修饰 (passive)
tmod - 时间修饰 (temporal modifier)
rcmod - 关系从句修饰 (relative clause modifier) (问题,遇到)
numod - 数量修饰(numeric modifier) (规定,若干)
ornmod — 序数修饰 (numeric modifier)
clf - 类别修饰(classifier modifier) (文件,件)
nmod - 复合名词修饰 (noun compound modifier) (浦东,上海)
amod - 形容词修饰(adjetive modifier) (情况,新)
advmod - 副词修饰(adverbial modifier) (做到,基本)
vmod - 动词修饰 (verb modifier, participle modifier)
prnmod - 插入词修饰 (parenthetical modifier)
neg - 不定修饰 (negative modifier) (遇到,不)
det - 限定词修饰 (determiner modifier) (活动,这些)
possm - 所属标记 (possessive marker), NP
poss - 所属修饰 (possessive modifier), NP
dvpm - DVP 标记 (dvp marker), DVP (简单,的)
dvpmod - DVP修饰(dvp modifier), DVP (采取,简单)
assm - 关联标记 (associative marker), DNP (开发,的)
assmod - 关联修饰(associative modifier), NP|QP (教训,特区)
prep - 介词修饰 (prepositional modifier) NP|VP|IP (采取, 对)
clmod - 从句修饰(clause modifier) (因为,开始)
plmod - 介词性地点修饰 (prepositional localizer modifier) (在,上)
asp - 时态标词 (aspect marker) (做到,了)
partmod- 分词修饰 (participial modifier) 不存在
etc - 等关系 (etc) (办法,等)
中心语为实词
conj - 联合(conjunct)
cop - 系动(copula) 双指助动词????
cc - 连接(coordination),指中心词与连词 (开发,与)
其它
attr - 属性关系 (是, 工程)
cordmod- 并列联合动词(coordinated verb compound) (颁布,实行)
mmod - 情态动词 (modal verb) (得到,能)
```

```
ba — 把字关系
tclaus — 时间从句 (以后,积累)
— semantic dependent
cpm — 补语化成分 (complementizer), 一般指"的"引导的 CP (振兴,的)
```

2、 英文原语料:

Nothing is impossible to a willing heart. Compared with harvard university diploma, reading habits are more important. Big success depends on team, small success depends on individual.

```
start stanfordcorenlp parse and dependency_parse with Chinese:>>>

parse:
(ROOT
(IP
(NP (NR Nothing))
(VP (VC is)
(VP (VC is)
(VP (V is)
(VP (D is)
(NP
(QP (CD a))
(NP
(NP (NN willing) (NN heart)))))
```

(PU .))

dependency parse:
[('ROOT', 0, 1), ('dep', 1, 2), ('root', 2, 3), ('case', 7, 4), ('dep', 6, 5), ('compound:nn', 7, 6), ('nmod:prep', 3, 7), ('punct', 3, 8), ('ROOT', 0, 1), ('root', 1, 2), ('nmod', 5, 3), ('amod', 5, 4), ('dep', 14, 5), ('punct', 14, 6), ('amod', 8, 7), ('nsubj', 14, 8), ('cop', 14, 9), ('nummod', 14, 10), ('mark:clf', 10, 11), ('amod', 13, 12), ('compound:nn', 14, 13), ('root', 2, 14), ('parataxis:prnmod', 14, 15), ('root', 15, 16), ('punct', 16, 17), ('compound:nn', 20, 18), ('compound:nn', 20, 19), ('root', 17, 20), ('case', 22, 21), ('dep', 20, 22), ('punct', 22, 23)]

二、 使用 pyltp 进行中文的依存句法分析:

1、 先利用 pyltp 进行分词:

```
分词结果:
                                                  天临
                                                                辛芷蕾
                  风波
                                                         与
助
》
                                            翟
两
联盟
f
                                                                      2:0
定档
                                                                                   西班牙人
武磊
       替补
             登场
                          梅西
                                 独
                                       中
                                                   元
                                                                巴萨
                                                                            战胜
                    ,
微博
      威影业
                                        复仇者
                                                     4
                                                                  正式
                                                                               4月
                                                                                     24日
                                                                                            在
                                                                                                  内地
                                                                                                         上映
                           宣布
              官方
                                                  的
                                                                             列入
                                                                                    新増
                               呼声
                                            高批
                                                        人工智能
                                                                      被
           29日
                                     极
                                                                专业
                                                                                                  本科
                                                                                                        专业
                                                                                                               名单
      共有
                   所
全国
                         高校
                                获
                                      首
                                                  建设
                                                         资格
             35
ACM
Hinton 获得
                        深度的
           宣布
                                     的
                                                  位
                                                        创造者
                                                                Yoshua Bengio ,
                                                                                      LeCun
                                                                                                  以及
                                                                                                         Geoffrey
                  ,
2019年
                               图灵奖
```

2、而后词性标注:

词性标注结用

P-3 11 P	himman.																				
V	n	V	n	nt	nd	wp	nh	V	p	nh	V	V	wp	nh	V	V	wp	nh	d	V	m
q	V	nz	m	V	n	wp	V	n	n	nz	V	wp	n	n	m	wp	a	V	nt	nt	p
nl	V	wp	V	nt	nt	nt	wp	n	d	а	u	n	n	р	V	V	V	n	n	n	wp
n	V	m	q	j	V	m	q	V	n	wp	WS	V	wp	n	V	u	m	q	n	WS	WS
wp	WS	WS	wp	C	WS	WS	V	u	nt	u	n	wp									

LTP 使用 863 词性标注集:

Tag	Description	Example	Tag	Description	Example		
a	adjective	美丽	ni	organization name	保险公司		
b	other noun-modifier	大型, 西式	nl	location noun	城郊		
С	conjunction	和, 虽然	ns	geographical name	北京		
d	adverb	很	nt	temporal noun	近日,明代		
е	exclamation	哎	nz	other proper noun	诺贝尔奖		
g	morpheme	茨, 甥	0	onomatopoeia	哗啦		

h	prefix	阿, 伪	р	preposition	在,把
i	idiom	百花齐放	q	quantity	个
j	abbreviation	公检法	r	pronoun	我们
k	suffix	界, 率	u	auxiliary	的,地
m	number	一,第一	v	verb	跑, 学习
n	general noun	苹果	wp	punctuation	, . !
nd	direction noun	右侧	ws	foreign words	CPU
nh	person name	杜甫, 汤姆	Х	non-lexeme	萄,翱
			Z	descriptive words	瑟瑟, 匆匆

3、依存句法分析结果:

句法分析结果:

6:ATT	3:ATT	4:ATT	6:ATT	6:ATT	9:ADV	6:WP	9:SBV	0:HED	12:ADV	10:POB	9:C00	12:C00	9:WP	16:SBV	9:C00	16:C00	16:WP	21:SBV	21:ADV	16:C00
23:ATT	24:SBV	21:VOB	24:V0B	27:ADV	24:V0B	27:VOB	9:WP	31:ATT	32:ATT	33:ATT	34:SBV	9:C00	38:WP	37:ATT	38:ATT	46:SBV	38:WP	46:ADV	46:SBV	43:ATT
46:ADV	46:ADV	44:POB	34:V0B	9:WP	9:C00	50:ATT	51:ATT	48:V0B	9:WP	55:SBV	55:ADV	58:ATT	55:RAD	58:ATT	60:FOB	60:ADV	9:C00	60:VOB	63:ATT	64:ATT
65:ATT	61:VOB	9:WP	68:SBV	9:C00	70:ATT	71:ATT	68:DBL	68:V0B	74:ATT	76:ATT	76:ATT	72:V0B	72:WP	79:SBV	72:C00	79:WP	82:ADV	86:ATT	82:RAD	85:ATT
86:ATT	88:ATT	88:ATT	96:SBV	88:WP	91:ATT	96:SBV	91:WP	95:LAD	95:ATT	96:SBV	79:V0B	96:RAD	100:ATT	98:RAD	96:VOB	9:WP				
test f	nichedl																			

pyltp 依存句法关系标注注释表:

关系类型	Tag	Description	Example
主谓关系	SBV	subject-verb	我送她一束花(我〈- 送)
动宾关系	VOB	直接宾语, verb-object	我送她一束花(送 -> 花)
间宾关系	IOB	间接宾语,indirect-object	我送她一束花(送 -> 她)
前置宾语	FOB	前置宾语,fronting-object	他什么书都读(书〈- 读)
兼语	DBL	double	他请我吃饭(请 -> 我)
定中关系	ATT	attribute	红苹果(红〈- 苹果)
状中结构	ADV	adverbial	非常美丽(非常〈- 美丽)
动补结构	СМР	complement	做完了作业(做 -> 完)
并列关系	COO	coordinate	大山和大海(大山 -> 大海)
介宾关系	POB	preposition-object	在贸易区内(在 -> 内)

左附加关系	LAD	left adjunct	大山和大海(和〈- 大海)
右附加关系	RAD	right adjunct	孩子们(孩子 -> 们)
独立结构	IS	independent structure	两个单句在结构上彼此独立
核心关系	HED	head	指整个句子的核心

结论分析与体会:

通过使用 stanfordcorenlp 和哈工大的 ltp 工具对中文进行依存句法分析结果的比较,就结果而言,各有特色,ltp 使用简单,标注的结果简单易分析,可以满足一般对依存句法分析要求不高的应用,而且速度较快;而 stanfordcorenlp 的分析进行的多层标注,标注更加丰富,可以利用标注结果进行更具选择和复杂的应用,可以利用的信息更多。

附录源代码:

```
# -*- coding: utf-8 -*-
Created on Mon Apr 1 09:36:20 2019
@author: wangbin
import os
from stanfordcorenlp import StanfordCoreNLP
from pyltp import Parser
from pyltp import Segmentor
from pyltp import Postagger
def test Snlp en(document):
   print("start stanfordcorenlp parse and dependency parse with English:>>>")
StanfordCoreNLP(r'D:\anaconda\Lib\stanford-corenlp-full-2018-02-27')
   pra = nlp.parse(document)
   d_pra = nlp.dependency_parse(document)
   nlp.close() # Do not forget to close! The backend server will consume a lot
memery.
   print("parse: \n",pra)
   print("dependency parse: \n",d pra)
def test Snlp zh(document):
```

```
print("start stanfordcorenlp parse and dependency parse with Chinese:>>>")
StanfordCoreNLP(r'D:\anaconda\Lib\stanford-corenlp-full-2018-02-27',lang =
'zh')
   pra = nlp.parse(document)
   d pra = nlp.dependency parse(document)
   nlp.close() # Do not forget to close! The backend server will consume a lot
memery.
   print("parse: \n",pra)
   print("dependency parse: \n",d pra)
def test ltp(document):
   LTP DATA DIR = r"D:\anaconda\envs\TF+3.5\Lib\site-packages\pyltp-model"
   # ltp 模型目录的路径
   par model path = os.path.join(LTP DATA DIR, 'parser.model') # 依存句法分析
模型路径,模型名称为`parser.model`
   cws model path = os.path.join(LTP DATA DIR, 'cws.model') # 分词模型路径,模
型名称为`cws.model`
   pos model path = os.path.join(LTP DATA DIR, 'pos.model') # 词性标注模型路径,
模型名称为`pos.model`
   segmentor = Segmentor() # 初始化实例
   segmentor.load(cws model path) # 加载模型
   words = segmentor.segment(document) # 分词
   print("\nA")
   print("分词结果: ")
   print ('\t'.join(words))
   segmentor.release() # 释放模型
   postagger = Postagger() # 初始化实例
   postagger.load(pos model path) # 加载模型
   postags = postagger.postag(words) # 词性标注
   print("\n")
   print("词性标注结果: ")
   print ('\t'.join(postags))
   postagger.release() # 释放模型
   parser = Parser() # 初始化实例
```

```
parser.load(par model path) # 加载模型
   arcs = parser.parse(words, postags) # 句法分析
   print("\n")
   print("句法分析结果: ")
   print("\t".join("%d:%s" % (arc.head, arc.relation) for arc in arcs))
   parser.release() # 释放模型
def main():
   f = open('chinese_sen2.txt','r',encoding='utf-8',errors='ignore')
   document = f.read()
   f.close()
   print(document)
   print("start ltp chinese test>>>")
   test ltp(document)
   test_Snlp_zh(document)
   f = open('english sen.txt')
   doc = f.read()
   f.close()
   print(doc)
   print("\n")
   test Snlp zh(doc)
   print("test finished!")
if __name__ == '__main__':
   main()
```